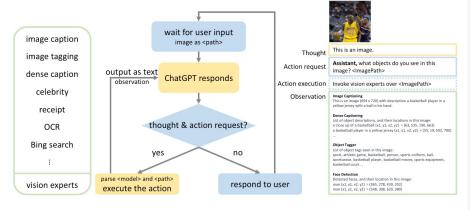
## MM-ReAct (arXiv 2023)

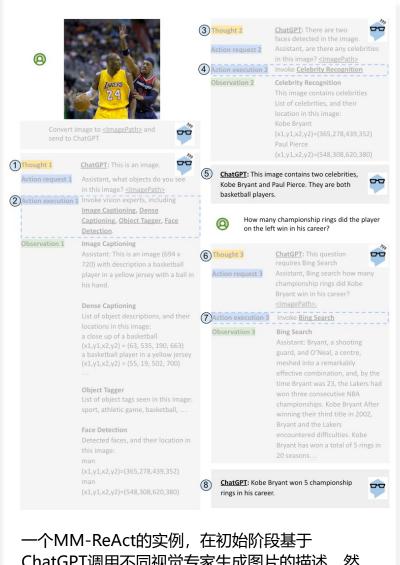
Motivation: 现有视觉语言模型的能力有效,在一些具体任务上没有特定任务模型好,本文融合不同的特定任务模型完成多任务下的视觉推理和行动。

整体思路: MM-REACT定义了一系列高级视觉任务,并引入了一种文本提示设计,可以表示文本描述、文本化的空间坐标,以及以对齐文件名表示的图像和视频等密集视觉信号。



**目的**: 汇聚众多视觉专家,为ChatGPT赋予视觉理解能力。 利用ReAct调用多个视觉模型为ChatGPT形成文本的caption。

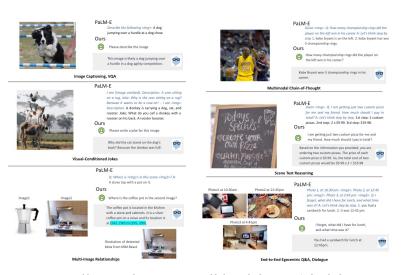
- 1. 用户输入:由于ChatGPT无法直接处理图片与视频,因此在输入时将图片与视频用路径代替,并让ChatGPT调用视觉专家模型从不同角度理解图像内容;
- **2. ChatGPT回复**: ChatGPT有两种回复,第一种是直接回复文本,第二种是调用视觉专家;
- 3. 视觉专家:给定ChatGPT的操作请求,使用正则表达式解析专家名和文件路径,并调用相关操作;视觉专家的输出格式可能是多种形式的,为了方便ChatGPT理解,需要将其转化成文本形式。



一个MM-ReAct的实例,在初始阶段基于 ChatGPT调用不同视觉专家生成图片的描述,然 后结合用户的问题,让ChatGPT进一步选择调用 专家还是生成回复,从而得到最终的答案。



通过为ChatGPT配备不同的视觉专家,它可以有效解决以上8种任务:视觉数学计算、理解视觉笑话、空间和坐标理解、视觉规划与预测、多图推理等任务。



采用了一些Case与PaLM-E进行对比,通过对比可知MM-ReAct的效果更优。